

POLITECNICO DI TORINO

CORSO DI LAUREA MAGISTRALE IN INGEGNERIA
INFORMATICA



Tesi di Laurea Magistrale

**Riconoscimento di dispositivi di
protezione individuale in ambito
industriale tramite infrastruttura
cloud**

Relatore:
Prof. Luca Ardito

Candidato:
Rei Zoto

Dicembre 2024

Indice

Elenco delle figure	5
1 Introduzione	8
2 Background	11
2.1 Infortuni, Sicurezza Industriale e DPI	11
2.2 Computer Vision	17
2.3 Cloud Computing nell'Industria	21
2.4 Amazon Rekognition	23
2.5 Lavori Simili	24
3 Tecnologie e Servizi	25
3.1 Docker	25
3.2 MQTT	29
3.3 Protocolli di streaming	32
3.4 Amazon Web Services	37
3.5 Apache Flink	42
4 Implementazione del sistema	43
4.1 Architettura	43
4.2 Edge Runtime/Ingestion	48
4.3 Preprocessing e trasformazione dei dati	48
4.4 Big data processing	48
4.5 Deployment	48
5 Risultati	49
5.1 Metriche ed Analisi	49
5.2 Limitazioni	49

Conclusioni	51
A Codice	53
B Approfondimenti Tecnici	55
Bibliografia	59

Elenco delle figure

2.1	Infortuni sul lavoro accertati positivi per genere e modalità di accadimento nell'anno 2022.	11
2.2	infortuni in occasione di lavoro accertati positivi per settore di attività nell'anno 2022	12
2.3	onere economico complessivo stimato (approccio bottom up)	13
2.4	stima dei costi complessivi approccio top down	14
2.5	Modello del neurone artificiale sulla base del funzionamento di un neurone biologico.	17
2.6	Gatto di Hubel e Wiesel[5]. Questi studi hanno permesso di dare una definizione di recettore visivo, scoprire l'organizzazione gerarchica della corteccia visiva nei mammiferi e formalizzare il concetto di retinotopia.	19
2.7	Lenet-5(1998). Primo modello ad aver dimostrato l'efficacia delle reti convoluzionali (CNN) nella comprensione delle immagini e ha aperto la strada a molte delle architetture moderne di deep learning. Crediti: Fei-Fei Li, CS231(Stanford).	21
2.8	Rilevamento tramite Rekognition dei dispositivi di sicurezza individuali.	24
3.1	Confronto tra macchine virtuali tradizionali e containers. . .	25
3.2	Esempio di condivisione di layers in Docker. Le due immagini risultanti hanno lo stesso sistema di base, condividendo lo stesso ambiente (Debian) e runtime (Python).	28
3.3	Schema architettura publish-subscribe.	29
3.4	Flusso pacchetti di controllo per QoS2. I livelli più semplici funzionano in maniera simile, con un numero di pacchetti inferiore. Si può notare come il disaccoppiamento fornito dal broker faciliti lo scambio dei messaggi.	31

3.5	Effetto del jitter nella riproduzione dello streaming. Senza buffering i pacchetti non vengono riprodotti seguendo la stessa temporizzazione della sorgente.	33
3.6	Stack di protocolli per lo streaming real-time.	34
3.7	Classificazione ad alto livello dei servizi AWS. Accessibili attraverso API, si dividono nelle due macro-aree hardware e software.	39
4.1	Schema dello use case.	44
4.2	Architettura ad alto livello del sistema.	44
4.3	Sottosistema di ingestion e preprocessing.	46
4.4	Moduli di processamento e generazione degli allarmi.	47

Capitolo 1

Introduzione

La sicurezza sul lavoro rappresenta un elemento fondamentale all'interno dell'industria manifatturiera, dove l'interazione tra macchinari complessi e operai espone a numerosi rischi. Come noto, gli infortuni sul lavoro nel settore manifatturiero sono tra i più frequenti e gravi, con conseguenze significative sia per i lavoratori che per le aziende. Garantire un ambiente di lavoro sicuro non solo tutela la salute e il benessere dei dipendenti, ma contribuisce anche a migliorare la produttività e a ridurre i costi associati agli incidenti. Essi infatti possono comportare gravi conseguenze per i lavoratori, inclusi infortuni permanenti, invalidità e, in casi estremi, decessi. Tali incidenti non solo influiscono sulla qualità della vita dei dipendenti e delle loro famiglie, ma comportano anche ripercussioni economiche rilevanti per le aziende. I costi diretti includono spese mediche e indennità di infortunio, mentre i costi indiretti comprendono la perdita di produttività, la necessità di sostituzione del personale e i danni alla reputazione aziendale. Oltre alle conseguenze dirette sugli individui, gli incidenti sul lavoro hanno un impatto economico significativo sulle aziende e sulla società nel suo complesso. Le aziende devono affrontare spese legali, aumenti dei premi assicurativi e potenziali sanzioni normative in caso di inadempienza alle leggi sulla sicurezza. Inoltre, la perdita di fiducia dei consumatori e dei partner commerciali può influenzare negativamente le performance finanziarie e la competitività dell'azienda sul mercato. Sul piano sociale, gli incidenti sul lavoro contribuiscono a un aumento dei costi sanitari e riducono la produttività nazionale. La società nel suo complesso subisce un impatto economico derivante dalla perdita di forza lavoro qualificata e dall'aumento delle richieste di assistenza sociale. Pertanto, investire nella sicurezza sul lavoro rappresenta non solo

un obbligo etico e legale, ma anche una strategia economica vantaggiosa a lungo termine.

I Dispositivi di Protezione Individuale (DPI) sono strumenti essenziali per prevenire gli incidenti sul lavoro e ridurre l'esposizione dei lavoratori a rischi specifici. DPI comuni includono caschi, guanti, occhiali protettivi, maschere respiratorie e indumenti resistenti agli agenti chimici. L'uso corretto e costante dei DPI è fondamentale per garantire la sicurezza dei lavoratori, ma la loro efficacia dipende dalla conformità e dalla corretta applicazione delle normative da parte dei dipendenti. Inoltre, monitorare l'uso dei DPI in ambienti industriali può risultare complesso, soprattutto in contesti ad alta dinamicità e con elevati volumi di produzione. Tradizionalmente, questo monitoraggio è stato effettuato attraverso ispezioni manuali, che possono essere dispendiose in termini di tempo e risorse e soggette a errori umani. Pertanto, vi è una crescente necessità di soluzioni automatizzate e tecnologicamente avanzate per garantire un controllo efficace e continuo dell'utilizzo dei DPI. L'innovazione tecnologica ha aperto nuove prospettive per migliorare la sicurezza sul lavoro nell'industria manifatturiera. In particolare, la computer vision e il cloud computing emergono come strumenti potenti per automatizzare il rilevamento dei DPI e monitorare in tempo reale le condizioni di sicurezza.

La **computer vision** permette alle macchine di interpretare e analizzare immagini e video, identificando automaticamente la presenza e l'uso corretto dei DPI. Attraverso algoritmi di deep learning, i sistemi di computer vision possono riconoscere oggetti specifici, come caschi e guanti, e verificare la loro corretta indossatura da parte dei lavoratori. Questo approccio non solo aumenta l'efficienza del monitoraggio, ma riduce anche la dipendenza da interventi manuali, minimizzando gli errori e garantendo una supervisione costante e accurata. Il **cloud computing**, d'altra parte, fornisce l'infrastruttura necessaria per gestire e analizzare grandi quantità di dati provenienti dai sistemi di computer vision. Attraverso piattaforme cloud, è possibile archiviare, elaborare e accedere ai dati in modo scalabile e flessibile, permettendo una gestione centralizzata e accessibile delle informazioni sulla sicurezza. Inoltre, il cloud computing facilita l'integrazione con altri sistemi aziendali, consentendo una visione completa delle operazioni e una risposta tempestiva agli incidenti rilevati. L'integrazione di computer vision e cloud computing rappresenta quindi una svolta nel campo della sicurezza industriale, offrendo soluzioni avanzate per il monitoraggio dei DPI e la prevenzione degli incidenti.

In questo contesto, la presente tesi si propone di sviluppare un sistema basato su Amazon Rekognition, un servizio di computer vision offerto da Amazon Web Services (AWS), per il rilevamento automatico dei DPI nell'industria manifatturiera. L'obiettivo principale è quello di generare una infrastruttura scalabile per l'analisi di dati semistrutturati e non strutturati all'interno di una fabbrica. In particolare, dato un insieme di macchinari, come ad esempio bracci robotici, si vuole ottenere il controllo dell'effettivo indossamento dei dispositivi di sicurezza da parte degli operatori (operai, manutentori) all'interno di uno stabilimento, in modo tale da garantirne loro la sicurezza sul posto di lavoro.

Capitolo 2

Background

2.1 Infortuni, Sicurezza Industriale e DPI

In questa sezione si vedranno delle statistiche relative agli infortuni sul lavoro, quale sia la risposta normativa al problema della sicurezza industriale dal punto di vista degli attori coinvolti, integrata con la definizione di dispositivi di sicurezza. Questo tema è di primaria importanza per garantire non solo la salute e il benessere dei lavoratori, ma anche l'efficienza operativa e la sostenibilità economica delle aziende. Secondo i dati forniti dall'Istituto Nazionale per l'Assicurazione contro gli Infortuni sul Lavoro (INAIL), nel 2022 il settore manifatturiero ha registrato un tasso di infortuni del 13,9% sul totale [1].





Figura 2.1: Infortuni sul lavoro accertati positivi per genere e modalità di accadimento nell'anno 2022.



Fonte: Open data Inail. Data di rilevazione 30/04/2023

Figura 2.2: infortuni in occasione di lavoro accertati positivi per settore di attività nell'anno 2022

Essi comportano gravi conseguenze per i dipendenti, inclusi infortuni permanenti, invalidità e, nei casi più gravi, decessi. Oltre al costo umano, gli incidenti sul lavoro hanno un impatto significativo sull'economia delle aziende, generando costi diretti come spese mediche e indennità di infortunio, e costi indiretti come perdita di produttività, danni reputazionali e aumento dei premi assicurativi. L'EU-Occupational Safety and Health Administration (EU-OSHA) a questo proposito ha stimato in due diversi approcci l'impatto degli incidenti sul lavoro all'interno dell'Unione Europea[2]. Nell'indagine sono stati presi in esame i dati relativi a 5 Paesi, poiché più completi e accessibili (tra cui figura anche l'Italia) e sono stati mostrati i risultati seguendo due diversi approcci: uno bottom-up, perché prende i valori dei costi per ciascun infortunio e li valuta globalmente; l'altro top-down, in quanto stima l'impatto dell'infortunio sulla vita del lavoratore e da valori macroeconomici come il PIL pro-capite valuta il costo effettivo dell'infortunio sul singolo. In termini pratici, nel primo caso si tiene conto dei costi diretti, indiretti e immateriali (effetti sulla vita e sulla salute) mentre nel secondo del valore monetario espresso in DALY, cioè il costo in termini di anni di vita persi a causa di un infortunio o di una malattia.

Paese		Finlandia	Germania	Paesi Bassi	Italia	Polonia
Numero di casi		131 867	2 262 031	323 544	1 907 504	1 156 394
Costi diretti	In Mio EUR	484	10 914	2 137	8 491	1 882
Costi diretti, % rispetto al totale		8	10	9	8	4
Costi indiretti	In Mio EUR	4 362	70 658	6 468	58 961	19 588
Costi indiretti, % rispetto al totale		72	66	69	56	45
Costi immateriali	In Mio EUR	1 196	25 557	5 147	37 392	22 311
Costi immateriali, % rispetto al totale		20	24	22	36	51
Onere economico complessivo	In Mio EUR	6 042	107 129	23 751	104 844	43 781
Percentuale rispetto al PIL		2,9	3,5	3,5	6,3	10,2

Figura 2.3: onere economico complessivo stimato (approccio bottom up)

Il risultato di queste analisi ha mostrato che per l'Italia il costo di un infortunio o malattia causata dal posto di lavoro aveva un impatto percentuale sul PIL del 6,3% nel primo caso, mentre nell'approccio top down, riferendosi alla metodologia VSLY - considerata più coerente con i risultati dell'approccio bottom up - il valore mediano era del 7,7% rispetto alla produzione interna.

I valori ottenuti, indipendentemente dall'approccio utilizzato, non si discostano troppo l'uno dall'altro, confermando l'attendibilità dell'analisi. Si può dedurre perciò quanto questo problema sia concreto e impatti sulla società e sull'economia dell'Italia, dove il posto di lavoro è in gran parte costituito dall'industria.

	Germania	Finlandia	Italia	Paesi Bassi	Polonia
DALY					
Totale dei DALY professionali	1 236 855	64 516	853 817	248 464	507 068
Percentuale rispetto ai DALY totali	4,9	4,2	5,1	5,7	4,0
DALY professionali per ogni 10.000 persone occupate	308	265	380	299	315

	Mio EUR	% rispet to al PIL	Mio EUR	% rispet to al PIL	Mio EUR	% rispet to al PIL	Mio EUR	% rispet to al PIL	Mio EUR	% rispet to al PIL
COSTI										
Approccio basato sul capitale umano										
Valore minimo	24 597	0,8	1 419	0,7	13 530	0,8	5 290	0,8	2 692	0,6
Media	55 429	1,8	3 106	1,5	31 475	1,9	11 879	1,7	6 929	1,6
Mediana	39 712	1,3	2 291	1,1	23 865	1,4	8 708	1,3	4 656	1,1
Massimo	138 404	4,5	7 393	3,5	69 671	4,2	30 114	4,4	17 037	4,0
Approccio WTP										
Valore minimo	32 324	1,1	1 637	0,8	20 929	1,3	3 276	0,5	5 118	1,2
Media	66 251	2,2	5 814	2,8	42 895	2,6	14 613	2,1	9 676	2,3
Mediana (*)	66 251	2,2	4 335	2,1	42 895	2,6	13 953	2,0	8 863	2,1
Massimo	100 177	3,3	17 453	8,3	64 861	3,9	30 767	4,5	15 861	3,7
Approccio VSLY/VOLY										
Valore minimo	60 609	2,0	4 214	2,0	52 304	3,2	9 649	1,4	12 790	3,0
Media	191 939	6,3	9 345	4,5	133 789	8,1	38 016	5,6	43 836	10,2
Mediana	166 943	5,5	8 633	4,1	126 876	7,7	33 248	4,9	31 026	7,2
Massimo	420 489	13,8	19 425	9,3	256 120	15,5	77 016	11,3	119 149	27,7

Figura 2.4: stima dei costi complessivi approccio top down

L'utilizzo corretto dei Dispositivi di Protezione Individuale (DPI) è fondamentale per prevenire tali incidenti. Secondo la legislazione italiana, per DPI si intende *qualsiasi attrezzatura destinata ad essere indossata e tenuta dal lavoratore allo scopo di proteggerlo contro uno o più rischi suscettibili di minacciarne la sicurezza o la salute durante il lavoro, nonché ogni complemento o accessorio destinato a tale scopo*[3].

La normativa in materia di sicurezza sul lavoro è un sistema complesso e articolato, volto a tutelare la salute e la sicurezza dei lavoratori in ogni settore produttivo. Il fulcro di questo sistema è rappresentato dal **Decreto Legislativo 81/2008**, conosciuto come *Testo Unico sulla Salute e Sicurezza sul Lavoro*. Questo decreto introduce una serie di obblighi inderogabili per i datori di lavoro, al fine di garantire un ambiente salubre e sicuro. Tra i principi cardine si evidenziano:

- **Valutazione dei rischi:** il datore di lavoro, con l'ausilio di un responsabile di sicurezza ed un medico esperto, è tenuto ad effettuare un'attenta e completa valutazione di tutti i rischi presenti sul luogo di lavoro, compresi anche per gruppi di lavoratori specifici. A questo scopo deve redarre un documento dove vengono presi in considerazione tutti i criteri utilizzati nella valutazione dei rischi.
- **Programmazione della prevenzione:** sulla base della valutazione dei rischi, il datore di lavoro, nello stesso documento, deve individuare i dispositivi di sicurezza necessari nelle attività lavorative ed elaborare un piano di prevenzione, nell'ottica di eliminare o ridurre al minimo i rischi individuati. Questo piano deve essere integrato con le condizioni tecniche, ambientali e produttive dell'azienda, garantendo la sua effettiva applicabilità e sostenibilità.
- **Informazione e formazione dei lavoratori:** i lavoratori devono essere informati in modo chiaro e completo sui rischi generali dell'azienda e su quelli specifici a cui sono esposti durante lo svolgimento delle loro mansioni, su come effettuare un primo soccorso e a chi rivolgersi nell'ottica di prevenzione dei rischi. Devono inoltre ricevere una formazione adeguata sulla loro prevenzione, adottare comportamenti sicuri e utilizzare correttamente macchinari e dispositivi di protezione individuale. L'informazione e la formazione devono essere fornite prima dell'inizio dell'attività lavorativa e devono essere ripetute periodicamente, garantendo l'aggiornamento costante dei lavoratori, nel caso ad esempio vengano cambiate le mansioni, oppure siano introdotte nuove attrezzature e tecnologie.
- **Sorveglianza sanitaria:** questa misura è fondamentale per monitorare lo stato di salute degli operatori in relazione ai rischi cui sono esposti, prevenire l'insorgenza di malattie professionali e garantire l'idoneità alla mansione. La sorveglianza sanitaria è effettuata da un medico competente, che ha il compito di visitare i lavoratori, effettuare gli accertamenti sanitari necessari e rilasciare il giudizio di idoneità.

I DPI rappresentano l'ultima barriera di protezione, quando le misure tecniche e organizzative non sono sufficienti a eliminare o ridurre i rischi. Pertanto, la loro scelta, il loro utilizzo e la loro manutenzione devono essere effettuati con la massima attenzione e responsabilità. Vengono suddivisi nelle seguenti categorie in base alla loro funzione:

- **Protezione della testa:** caschi di protezione per l'industria.
- **Protezione dell'udito:** cuffie antirumore, tappi auricolari.
- **Protezione degli occhi e del viso:** occhiali protettivi, visiere.
- **Protezione delle vie respiratorie:** mascherine antipolvere e respiratorie.
- **Protezione degli arti superiori e inferiori:** guanti di protezione, scarpe antinfortunistiche, ginocchiere.
- **Indumenti di protezione:** tute, grembiuli, indumenti ad alta visibilità.

Gli standard, giocano un ruolo fondamentale nel definire tecnicamente i criteri di produzione, utilizzo e manutenzione dei DPI, garantendo un elevato livello di protezione per gli utenti. La legge europea, come evidenziato nel **Regolamento (UE) 2016/425** stabilisce i requisiti che i DPI devono soddisfare nel mercato unico[4], tra cui:

- **Ergonomia:** i DPI devono essere progettati e fabbricati in modo da essere comodi da indossare e non limitare la libertà di movimento del lavoratore, evitando di interferire con lo svolgimento delle sue attività, garantendone allo stesso tempo la sicurezza.
- **Livelli e classi di protezione:** i DPI devono fornire un livello di protezione adeguato al rischio specifico da cui proteggono. La classificazione dei DPI in base al livello di protezione consente di scegliere il dispositivo più idoneo in relazione al rischio da prevenire.
- **Marcatura:** i DPI devono essere marcati con il simbolo **CE**, a indicare la loro conformità ai requisiti di sicurezza dell'Unione Europea. La marcatura CE deve essere apposta in modo visibile, leggibile e indelebile sul DPI o sulla sua confezione.
- **Istruzioni e informazioni del fabbricante:** i DPI devono essere accompagnati da istruzioni chiare e complete (e.g. rischi coperti, prestazioni, classi di protezione, accessori, pezzi di ricambio etc.) per l'utilizzatore, che indichino in modo dettagliato come utilizzare, conservare, pulire e mantenere correttamente il dispositivo. Le istruzioni devono

essere redatte in una lingua comprensibile nello Stato membro in cui il DPI è commercializzato. I dispositivi fabbricati devono avere una sorgente (il produttore e il suo indirizzo) ed essere identificati dal lotto messo in commercio.

2.2 Computer Vision

La computer vision è un campo dell'informatica incentrata sulla comprensione del contenuto di immagini o video per mezzo di un calcolatore. I task che si possono svolgere sono di diversi tipologie, tra cui la classificazione, l'object detection, la segmentazione, il riconoscimento di volti, l'encoding e l'applicazione di filtri per la modifica delle immagini originali. La ricerca sulle reti neurali nell'ambito della computer vision è stata tra le prime a mostrare le potenzialità di questa tecnologia nella risoluzione di problemi nel mondo reale. Storicamente l'insieme di diversi sviluppi nelle discipline di neuroscienza, deep learning e matematica ha permesso il raggiungimento di questo traguardo. Le scoperte relative al neurone biologico, la modellazione dei primi neuroni artificiali e la successiva estensione a più strati, l'utilizzo del calcolo differenziale per l'aggiornamento dei pesi, l'introduzione di funzioni di attivazione e di perdita sempre più complesse, ed infine la formulazione del teorema di approssimazione universale sono sicuramente gli elementi fondamentali di questo successo. Alla fine degli anni '50 è stato modellato il primo neurone artificiale, prendendo ispirazione dal neurone biologico, composto dalla combinazione lineare di input e pesi in ingresso ad una funzione di attivazione.




Figura 2.5: Modello del neurone artificiale sulla base del funzionamento di un neurone biologico.

Questo semplice meccanismo era in grado di mimarne grossolanamente il comportamento, generando una risposta a dei dati in ingresso, in modo tale che, superata una certa soglia, producesse o meno un valore in uscita. La funzione di attivazione era una semplice funzione gradino (al tempo non era scontato generare funzioni non lineari e continue), ma comunque questo oggetto era in grado di risolvere problemi di classificazione binaria. Il limite principale di questo modello consisteva nell'aggiornamento dei pesi in caso di predizioni sbagliate, basato su una delta di valori discreti. La funzione di aggiornamento dei pesi forniva in maniera euristica una direzione verso l'insieme ottimale delle variabili interne al modello, per ottenere la predizione il più possibile corretta ad ogni nuovo input.

Per risolvere questo limite, venne definita una funzione di attivazione continua, trasformando il problema da uno di classificazione ad uno di regressione. Questa nuova costruzione permetteva di introdurre una funzione di perdita, nell'ottica di minimizzare l'errore nelle predizioni attraverso un approccio più rigoroso. Dalla teoria delle regressioni lineari infatti si poteva utilizzare il metodo dei minimi quadrati, che in termini pratici significava ridurre il più possibile l'errore nella rappresentazione della funzione che si voleva apprendere dai dati. Fino alla fine degli anni '60 si sperimentò l'utilizzo di questi modelli, di cui gli esempi più famosi sono Adaline e Madaline, costituiti da semplici reti di neuroni artificiali, rispettivamente ad uno e due strati. Esse non riuscivano a rappresentare correttamente le non linearità all'interno della distribuzione dei dati, ma si trattava solo di un limite tecnico e non teorico, poiché non erano ancora state introdotte funzioni di attivazione non lineari continue come la sigmoide e non era ancora stato compreso come propagare l'aggiornamento dei pesi negli strati nascosti.

Nella seconda ondata di ricerca sulle reti neurali, iniziata negli '80, è stato dimostrato che è teoricamente possibile approssimare qualsiasi distribuzione dei dati attraverso l'apprendimento automatico di reti neurali con almeno uno strato di neuroni artificiali, aventi delle funzioni di attivazione non lineari. Questo teorema prende il nome di teorema di approssimazione universale. Esso si applica a tutte le tipologie più comuni di problemi risolti nel machine learning, quindi problemi discriminativi come la classificazione e la regressione e problemi generativi, come ad esempio l'encoding di immagini, la generazione di testo etc. Le implicazioni di questa dimostrazione hanno avuto un forte impatto solo in tempi più recenti, ma per comprenderne appieno le cause bisogna ancora revisionare alcuni elementi fondamentali in

questa storia. Dalla neuroscienza infatti, non si è soltanto preso ispirazione per la modellazione del perceptron, tant'è che a partire dagli anni '50 è stato studiato il funzionamento della corteccia visiva nel cervello di alcuni mammiferi. Fondamentalmente con questi studi è stato dimostrato che i neuroni all'interno di questa zona sono organizzati gerarchicamente e nel livello più semplice rispondono a stimoli visivi con caratteristiche specifiche, come l'orientamento e le traslazioni.

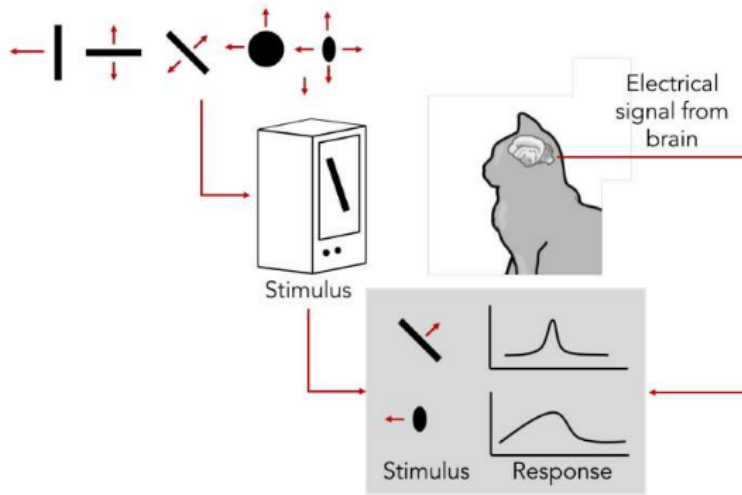


Figura 2.6: Gatto di Hubel e Wiesel[5]. Questi studi hanno permesso di dare una definizione di recettore visivo, scoprire l'organizzazione gerarchica della corteccia visiva nei mammiferi e formalizzare il concetto di retinotopia.

Nel 1980 venne proposto il Neocognitron, un antenato delle moderne reti convoluzionali. In questo modello sono stati trasposti i precedenti principi, in quanto, oltre ad implementare una architettura gerarchica con strati di neuroni, è stato definito matematicamente come modellare dei campi recettivi, cioè in che modo identificare delle forme semplici con diverse orientazioni dall'immagine di input, come succede per i recettori delle immagini provenienti dal campo visivo oculare. La definizione è stata presa dalla teoria dei segnali usando la formula della convoluzione:

$$y[n] = (x * h)[n] = \sum_{k=-\infty}^{+\infty} x[k] \cdot h[n - k] \quad (2.1)$$

Classicamente, questa espressione permette la generazione di diversi filtri, in modo tale da modulare o isolare solo parti del segnale di interesse, eliminandone altre che possono non essere utili a successive trasformazioni o semplicemente perché fonti di rumore. Nel dominio dell'immagine processing si voleva sfruttare esattamente questa proprietà: applicare la funzione di convoluzione in modo da isolare le caratteristiche desiderate all'interno di una figura. Applicando questa formula nel dominio spaziale e definendo dei filtri bidimensionali, l'espressione assume la seguente forma:

$$y[i, j] = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} h[m, n] \cdot x[i - m, j - n] \quad (2.2)$$

Così non solo era possibile emulare il comportamento dei recettori visivi, ma allo stesso tempo si implementava il concetto di retinotopia. Il prodotto scalare di un filtro in una singola sezione dell'immagine genera la stessa formula di un neurone artificiale (vedi [Appendice B](#) per dettagli), per cui ogni attivazione all'interno di ciascuna feature map (il risultato di una intera convoluzione) simula esattamente il modello del perceptron. La retinotopia definisce una relazione locale tra elementi vicini del campo visivo e neuroni vicini all'interno della corteccia visiva. Allo stesso modo attivazioni vicine nella feature map corrispondono ad elaborazioni di elementi vicini nell'immagine. In questo modo si potevano identificare forme di interesse in diverse angolazioni. Per ottenere invece lo stesso effetto di invarianza dalla posizione delle forme nell'immagine - in altri termini l'identificazione di queste indipendentemente da traslazioni nell'immagine - sono stati definiti degli strati di pooling. Questo modello presentava principalmente un grosso limite: il metodo di allenamento non era supervisionato e non si basava su una funzione di perdita globale, infatti l'utilizzo della backpropagation non era ancora stato formalizzato. Gli strati più interni della rete non permettevano la rappresentazione di forme più complesse e più coerenti con l'oggetto da classificare. Inoltre la rete era addestrata per il pattern recognition, ma non aveva una utilità pratica rispetto ai problemi più comuni nella computer vision. L'introduzione di uno strato fully connected, l'utilizzo di una funzione di perdita globale per la classificazione e della backpropagation portarono all'architettura di Lenet, nel 1998. L'allenamento di questa rete era specifico per la classificazione e tutti i neuroni dell'architettura partecipavano al training, quindi anche quelli degli strati convoluzionali. In altre parole si trattava di una rete end-to-end. AlexNet, la rete che segna una netta linea di demarcazione nel deep learning, mantiene la stessa architettura,

con una principale differenza: le funzioni di attivazione all'interno della rete permettono la propagazione del gradiente senza saturazioni negli strati più interni.




Figura 2.7: Lenet-5(1998). Primo modello ad aver dimostrato l'efficacia delle reti convoluzionali (CNN) nella comprensione delle immagini e ha aperto la strada a molte delle architetture moderne di deep learning. Crediti: Fei-Fei Li, CS231(Stanford).

La riduzione dell'errore nei problemi di classificazione nei problemi di vision artificiale è stata solo una naturale conseguenza: l'architettura ormai era chiara e funzionante, si trattava solo di aumentare il numero di neuroni e strati all'interno della rete, grazie ad una potenza di calcolo che ai tempi di Lenet non era disponibile.

2.3 Cloud Computing nell'Industria

Il cloud computing rappresenta una delle innovazioni più rilevanti degli ultimi decenni nel settore IT, trasformando il modo in cui le aziende gestiscono le proprie risorse informatiche e processi produttivi. Questo nuovo paradigma, basato sull'erogazione di servizi tramite Internet, consente di accedere a risorse come server, storage, database e applicazioni software in modo scalabile e on-demand, senza dover effettuare investimenti iniziali significativi in infrastrutture hardware. Le implicazioni di questa trasformazione sono profonde, in quanto ridefiniscono i modelli di gestione IT e le strategie aziendali, favorendo un approccio più veloce e flessibile nell'implementazione di nuove soluzioni. La principale innovazione apportata dal cloud computing risiede nella possibilità di adattare rapidamente le risorse informatiche alle necessità aziendali, garantendo una scalabilità notevolmente superiore rispetto alle

infrastrutture tradizionali. In passato, le aziende che desideravano espandere i propri sistemi erano costrette a effettuare investimenti consistenti in hardware e a sostenere costi elevati per la relativa gestione e manutenzione. Inoltre, la diversa geolocalizzazione dei datacenter comporta vantaggi in termini di accessibilità, permette di risolvere problemi di latenza e di personalizzare i servizi in base alla regione in cui l'applicazione eseguita sul cloud viene deployata.

Oltre a facilitare la gestione delle risorse e ridurre i costi infrastrutturali, il cloud computing è considerato una tecnologia abilitante nell'implementazione dell'Industria 4.0. Ogni era industriale è stata segnata da una svolta tecnologica: nella prima l'introduzione della macchina a vapore, nella seconda l'elettrificazione delle macchine e la conseguente implementazione della catena di montaggio. La terza rivoluzione è stata possibile grazie all'invenzione del transistor e la successiva democratizzazione dei calcolatori. Questa nuova ondata invece è incentrata sui dati: ad esempio, nel 2015 è stato stimato che solo l'1% delle informazioni generate dai sensori all'interno di una fabbrica veniva effettivamente elaborata[6]. L'adozione di tecnologie quali l'Internet of Things (IoT), gli sviluppi moderni nell'intelligenza artificiale e l'analisi di big data sono gli elementi che concorrono a questa nuova rivoluzione. Il primo di questi fattori è fondamentale per la generazione e l'ingestion, mentre gli altri due per il processamento: indipendentemente dalle loro funzioni, i dati restano il fulcro delle operazioni. In questo contesto, il cloud fornisce l'infrastruttura e i servizi necessari per l'integrazione di questi elementi, rendendo possibile l'implementazione delle smart factories.

La capacità del cloud di raccogliere, archiviare ed elaborare grandi quantità di dati in tempo reale è cruciale per sfruttare appieno il potenziale dell'Industria 4.0. Le aziende che operano in settori industriali tradizionali, come la manifattura, possono trasformare le loro linee di produzione in sistemi autonomi e ottimizzati, capaci di adattarsi alle esigenze del mercato e di ridurre significativamente gli sprechi. La connettività fornita dal cloud consente invece di collegare dispositivi, sensori e macchinari all'interno della fabbrica, creando un ecosistema in cui ogni componente è in grado di comunicare e condividere le proprie informazioni, rendendo più semplice il monitoraggio dei processi produttivi. Inoltre con gli avanzamenti nella ricerca sul deep learning, diventato sempre più consistente negli anni, i relativi modelli sono stati adottati per migliorare diverse parti dell'ecosistema aziendale, come il monitoraggio, i processi decisionali e produttivi. Un esempio concreto è la manutenzione predittiva, che sfrutta i dati provenienti dai

sensori per rilevare anomalie e prevedere i guasti delle macchine. E' così possibile ridurre i tempi di inattività, prolungare la vita utile delle apparecchiature e migliorare la loro efficienza complessiva. Sempre nello stesso contesto, un'azienda potrebbe utilizzare il cloud per raccogliere e analizzare dati provenienti dalle linee di assemblaggio, applicando modelli di apprendimento automatico per migliorare la qualità dei componenti e ridurre i difetti di produzione.

2.4 Amazon Rekognition

Esistono diversi providers di servizi cloud, di cui uno dei più diffusi è Amazon Web Services (AWS). Fin dalla sua nascita è stato sempre considerato uno dei principali innovatori in questo dominio, non solo perché il primo ad avere introdotto il concetto di cloud nel 2006. Amazon è da sempre all'avanguardia nel fornire nuove funzionalità: è passata dalle risorse di calcolo on-demand e dei servizi gestiti come storage e database, all'introduzione del paradigma serverless, fino all'integrazione di servizi per l'IoT e per il machine learning. AWS infatti possiede un ricco ecosistema per la generazione di soluzioni basate sull'apprendimento automatico come SageMaker, Bedrock e Rekognition. Ciascuno risponde a esigenze specifiche: SageMaker funge da piattaforma di base per lo sviluppo e l'addestramento di modelli personalizzati, mentre Bedrock offre accesso a diversi foundation models, semplificando l'utilizzo di questa nuova tecnologia. Infine, Rekognition si posiziona come una soluzione specializzata per l'analisi di immagini, video e streaming, dove le aziende possono implementare le relative funzionalità senza dover sviluppare o addestrare modelli. Serve solo invocare la API di interesse. Rekognition è quindi particolarmente utile per le aziende che necessitano di integrazioni rapide e affidabili nell'ambito della visione artificiale all'interno dei loro processi. I casi d'uso spaziano su numerosi domini: ad esempio, può essere utilizzato per estrarre metadati da un testo scritto a mano, oppure per la moderazione dei contenuti nelle piattaforme social.

Nell'ambito di questo scritto, Rekognition viene usato per l'identificazione dei dispositivi di sicurezza e per la valutazione del loro corretto utilizzo. Dalla documentazione Amazon viene mostrato un esempio di questo servizio in azione. La API utilizzata è `DetectProtectiveEquipment`, che in questo caso è in grado di rilevare casco, maschera e guanti da lavoro. Più nel dettaglio, la risposta di questa richiesta sarà una struttura dati contenente: le persone



Figura 2.8: Rilevamento tramite Rekognition dei dispositivi di sicurezza individuali.

all'interno dell'immagine, le parti del corpo che indossano i dispositivi di sicurezza (differenziando ad esempio quale mano indossa i guanti), il tipo di dispositivi rilevati e l'associazione tra parti del corpo e dispositivi, in modo tale da verificare quali siano correttamente indossati. La chiamata può essere configurata per rilevare tutti i DPI più comuni oppure solo un sottoinsieme di essi in base alla necessità. Le API di Rekognition si differenziano in due possibili sottocategorie: storage e non-storage. La distinzione consiste nel fatto che il servizio può salvare o meno le informazioni relative all'analisi dell'immagine o del video. Per questioni di privacy, non viene tracciato alcun individuo e non c'è alcuna correlazione tra gli id restituiti da ciascun processamento. L'operazione è focalizzata solo sull'utilizzo regolare dei DPI e la documentazione è molto chiara in questo punto. Altre chiamate di Rekognition, come quelle basate sul riconoscimento facciale, hanno invece bisogno di salvare queste informazioni altrimenti non potrebbero funzionare.

2.5 Lavori Simili

Capitolo 3

Tecnologie e Servizi

3.1 Docker

Docker è diventato negli anni il sistema più popolare per gestire la virtualizzazione basata su container. Può essere visto come un tipo di macchina virtuale leggera, in quanto riesce a garantire le stesse caratteristiche di quelle tradizionali, ma con un overhead minore, sia in termini di efficienza nell'esecuzione, che di spazio occupato.




Figura 3.1: Confronto tra macchine virtuali tradizionali e containers.

Essi vengono eseguiti direttamente sul sistema operativo dell'host, senza la necessità di chiamate di sistema multiple. Vengono impacchettate solo le librerie necessarie nell'immagine di base fornita al container. In realtà, la

sua value proposition è legata alla possibilità di poter lanciare una applicazione ovunque, con la garanzia che questa funzioni sempre. L'analogia con i container nel mondo reale è diretta: quelli utilizzati nel commercio, possono essere adattati indipendentemente dall'ambiente di trasporto. Allo stesso modo l'applicazione che viene eseguita, funzionerà indipendentemente dall'ambiente di esecuzione, qualsiasi sistema operativo esso sia, con l'unica limitazione sull'execution set per cui è stata generata la build. Nella pratica, quindi, esistono due definizioni in base all'utilizzatore di questa tecnologia: se si parla di gestione di una infrastruttura, allora l'attenzione è spostata verso la virtualizzazione, mentre se il focus è relativo alle applicazioni, allora si può vedere Docker come una tecnologia orientata alla portabilità. In generale, le macchine virtuali devono garantire un serie di proprietà per poter essere definite tali, che sono:

- **consolidamento:** inizialmente ciascuna applicazione veniva eseguita su una macchina distinta, rendendo l'utilizzo delle risorse inefficiente. La virtualizzazione ha permesso di superare questa limitazione, con l'esecuzione di software differenti all'interno della stessa macchina.
- **isolamento:** questa proprietà consente ad ogni applicazione di vedere l'ambiente come se fosse una macchina a sé stante, nonostante il consolidamento. I sistemi operativi offrono funzionalità di isolamento base come l'astrazione dello spazio di indirizzamento di un processo, ma questo non è sufficiente per una applicazione self-contained. Diversi applicativi infatti possono interferire tra di loro già solo nell'utilizzo della memoria, nel caso di sovra-allocazioni, portando ad un degrado delle prestazioni o al crash(verifica). Lo stesso ragionamento si può applicare anche per la gestione della cpu, della rete e del filesystem che all'interno di un sistema operativo sono risorse completamente condivise tra processi.
- **flessibilità:** il controllo dei container è molto semplice in quanto docker prevede dei comandi standard per la loro gestione, come l'avvio, la pausa e lo stop. Gli orchestratori giocano un ruolo fondamentale per riallocare i container in nodi diversi dell'infrastruttura, per esempio in caso di manutenzione o sovraccarico. Questo processo avviene senza particolari overhead, in quanto i container, a differenza delle macchine virtuali tradizionali hanno dei tempi di attivazione molto bassi.

- **portabilità:** come già visto, i container possono essere avviati in qualsiasi piattaforma, indipendentemente dal sistema operativo, dall'hardware, dalle librerie necessarie e dalle loro versioni. Questo comporta un grande vantaggio anche nell'uso di linguaggi di programmazione di basso livello quando l'efficienza è fondamentale. Linguaggi come Java, ad esempio, si servono di macchine virtuali per poter garantire la portabilità del codice, ma il tempo di esecuzione aumenta notevolmente.

L'implementazione dei container è stata possibile grazie a due elementi presenti all'interno dei sistemi operativi: namespaces e control groups(cgroups). Si tratta di features che inizialmente non erano state pensate per la virtualizzazione, ma solo nell'ottica di avere dei processi isolati. Non si è quindi arrivati subito alla definizione di container, ma ci sono state delle tappe risolutive di diversi problemi che gli sviluppatori avevano all'inizio degli anni 2000. I namespaces permettevano la gestione della visibilità relativa alle risorse per ogni processo, mentre i cgroups servivano a limitare l'utilizzo di quanto allocato. Nel secondo caso, esistevano già dei meccanismi di questo tipo all'interno del kernel Linux (e.g. cpulimit, nice), ma non erano centralizzati e potevano essere applicati solo a singoli processi. L'evoluzione dei cgroups è fondamentalmente quella di estendere il tutto ad un gruppo di task in maniera modulare, con la possibilità di definire delle gerarchie nella gestione delle risorse. Le tecnologie basate su container come Docker hanno integrato questi meccanismi nel loro layer di virtualizzazione, in modo tale da fornire delle primitive di alto livello per la gestione dei container, che altrimenti con le precedenti astrazioni sarebbero accessibili solo ad utenti esperti, ed in ogni caso inclini ad errori a causa della complessità di utilizzo.

Docker presenta infine una particolarità a livello di filesystem: rispetto alle macchine virtuali tradizionali o container LXC, che sfruttano un filesystem in senso stretto, questa tecnologia utilizza il concetto di Union Filesystem.

Si tratta di un sistema che combina diversi filesystem restituendo logicamente un'unica struttura. Nell'implementazione di Docker, lo Union Filesystem si presenta come una gerarchia di strati, tutti in sola lettura, a cui ne viene aggiunto uno scrivibile al lancio del container. Questo meccanismo, come si può vedere in Figura 3.2 permette la condivisione della stessa immagine di base, evitando allo stesso tempo di dover duplicare lo spazio di memoria e che modifiche da parte di una macchina possano influenzare ciò che vedono gli altri container basati sulla stessa istanza, attuando così




Figura 3.2: Esempio di condivisione di layers in Docker. Le due immagini risultanti hanno lo stesso sistema di base, condividendo lo stesso ambiente (Debian) e runtime (Python).

un primo livello di isolamento (quello più generale con l'host viene sempre implementato attraverso i namespaces).

La realizzazione pratica di questa funzionalità è possibile grazie al concetto di copy-on-write, già utilizzato nella creazione dei processi. In questo caso il funzionamento è analogo, ma si applica a livello di memoria secondaria. Ogni modifica all'immagine di base, attraverso il layer in scrittura di più alto livello, è ciò che viene salvato. Non si apportano modifiche all'intera memoria: in pratica è un meccanismo basato sulle differenze. Una volta che si esegue il commit di un'immagine, gli strati vengono congelati e ne formano una nuova. Al livello dell'utilizzatore questo sistema si rivela molto utile perché si possono comporre nuove immagini impilando nuovi layer a quelli già esistenti, senza preoccuparsi dei livelli sottostanti, perché grazie alla portabilità il loro funzionamento è garantito. La composizione non è l'unica proprietà interessante che emerge da questa architettura, ma anche modularità, riutilizzo ed efficienza. Quest'ultima è importante sia in termini di spazio, perché come già visto i layer inferiori vengono condivisi, sia in termini di tempo. Quando si costruisce una nuova immagine, infatti, verranno aggiunti o scaricati solo gli strati di più alto livello per la generazione della nuova immagine, invece di dover ri-eseguire l'operazione ogni volta.

3.2 MQTT

Message Queue Telemetry Transport (MQTT) è un protocollo orientato ai messaggi, basato su TCP, il cui obiettivo è quello di fornire un protocollo leggero, per dispositivi con risorse limitate e connessioni instabili. Il formato dei dati infatti è semplice ed è pensato per essere affidabile e fault-tolerant. Proprio per le sue caratteristiche, con il tempo è diventato uno standard nelle applicazioni IoT, ad esempio monitoraggio remoto e raccolta di dati in industria, domotica e ambiente. MQTT si basa su un'architettura publish-subscribe. Ciò permette di disaccoppiare l'invio dei messaggi tra produttori e consumatori, attraverso un broker. Si tratta di un metodo di comunicazione indiretto, in quanto per chi pubblica non è necessario conoscere la destinazione, come invece avviene nelle architetture client-server. Il funzionamento è analogo a quello delle newsletter. Quando un utente è interessato ad un certo argomento, lascia il proprio indirizzo email, in modo tale da ricevere aggiornamenti. Analogamente in un sistema publish-subscribe le entità che devono ricevere determinati messaggi da un publisher, si iscrivono ad un canale.

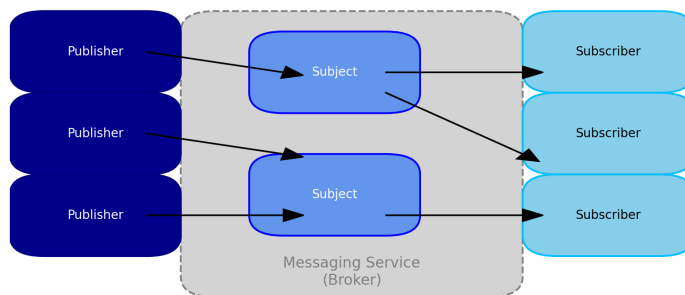


Figura 3.3: Schema architettura publish-subscribe.

Oltre al disaccoppiamento, questo tipo di pattern fornisce ulteriori vantaggi[7]. E' possibile aggiungere nuovi publisher o subscriber senza dover modificare la logica esistente, il che rende l'architettura facilmente scalabile. Si tratta di uno dei motivi per cui il cloud riesce a gestire facilmente milioni di messaggi in un breve intervallo di tempo ed avere migliaia di publishers.

Inoltre ogni parte del sistema non dipende dalle altre, favorendo la comunicazione asincrona, poiché nessun publisher deve aspettare per l'invio di nuovi messaggi prima che i consumatori finiscano. Allo stesso modo i consumatori non devono attendere che altri ricevano i messaggi per poter proseguire con l'elaborazione delle proprie informazioni. Questo tipo di pattern viene implementato in tanti sistemi come quelli delle notifiche push nelle applicazioni mobili, nei servizi gestiti del cloud ed infine nei sistemi IoT, attraverso il protocollo MQTT, focus dei paragrafi successivi. In questo contesto, le unità di interesse vengono descritte come topic. Essi sono univocamente definiti all'interno dei broker attraverso una struttura gerarchica che ricorda i path nelle URI. Ad esempio, un topic può essere dichiarato come: `factory/floor/sensor1`. Non esiste un meccanismo esplicito di creazione dei topic, ma vengono definiti contestualmente alla pubblicazione di un messaggio.

Il broker ha la responsabilità di connettere, se autorizzati, i diversi client della rete, di tenere traccia dello stato di connessioni precedenti e di filtrare i dati in arrivo dai publisher. Per il discorso di efficienza previsto da questo protocollo, infatti, devono essere distribuiti solo i pacchetti necessari al funzionamento del sistema, e quindi la capacità di filtro è un elemento fondamentale. In particolare, esistono diverse tipologie di controllo dei pacchetti in transito. Quello più importante è il topic filter, dove un messaggio deve contenere necessariamente un topic nell'header, e sarà compito del broker ritrasmetterlo o ignorarlo in base a come è stata implementata la sua logica. In generale i filtri vengono usati per riferirsi ad un insieme di topic, sfruttando due tipologie di wildcards. Si utilizza il segno "+" per indicare un intero livello nella gerarchia del path definito dal topic. Ad esempio `factory/+sensor1` serve per tutti i `sensor1` nei diversi piani di una fabbrica. Il secondo simbolo, cioè "#" si riferisce ad una intera sottogerarchia nel path. `factory/#` e `factory/first/#` filtrano rispettivamente tutti i messaggi provenienti dalla fabbrica e quelli provenienti dal primo piano di un complesso industriale.

MQTT è un protocollo progettato con l'affidabilità in mente: in base al contesto (hardware, banda, latenza) e al tipo di applicazione, fornisce diversi livelli di Quality of Service(QoS):

- **QoS0**: modalità di funzionamento default in MQTT, se non specificato. I messaggi vengono inviati con una logica fire-and-forget, senza la garanzia che il processo vada a buon fine. Il publisher o il broker inviano

i messaggi senza alcun tipo di risposta da parte di un subscriber. Non ci sono ulteriori garanzie oltre a quelle fornite dal protocollo TCP.

- **QoS1:** garantisce che il messaggio venga inviato almeno una volta. Questo meccanismo si basa su messaggi di acknowledgment provenienti dal ricevente, per cui se non arriva nessuna risposta, il messaggio deve essere ritrasmesso.
- **QoS2:** si tratta del livello di qualità più alto. Il messaggio viene inviato una sola volta, grazie ad una serie di messaggi di controllo generati dalle entità in gioco. Può essere visto come un acknowledgment incrociato tra publisher e ricevente. Quello che avviene in più rispetto a QoS1 è l'invio dei pacchetti publish-release per indicare il rilascio del messaggio dalla memoria del publisher, e publish-complete da parte del ricevente per chiudere la comunicazione. In questo modo alla fine del processo il messaggio è stato inviato e gli attori in gioco sono totalmente sincronizzati dal punto di vista della ricezione.

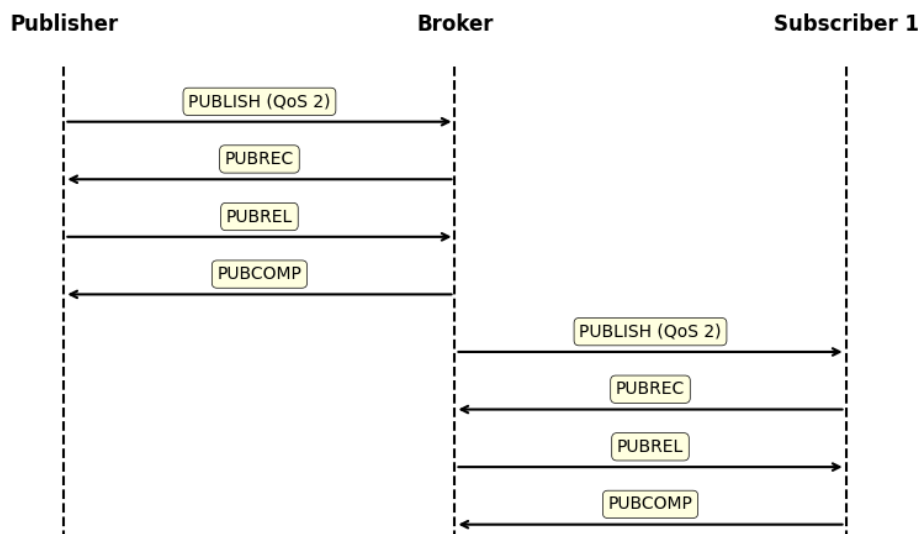


Figura 3.4: Flusso pacchetti di controllo per QoS2. I livelli più semplici funzionano in maniera simile, con un numero di pacchetti inferiore. Si può notare come il disaccoppiamento fornito dal broker faciliti lo scambio dei messaggi.

Il QoS viene negoziato al momento della connessione con il broker, ed in base alle sue capacità può essere dinamicamente modificato in un secondo

momento. Nell'affrontare il concetto di qualità di servizio, si è visto quindi il funzionamento della publish da parte di un client, ma esistono altri tipi di operazioni in questo pattern, cioè subscribe, unsubscribe e ping. In particolare quest'ultimo risulta fondamentale per l'implementazione del Last Will and Testament (LWT), un metodo per comunicare la disconnessione di un publisher all'interno della topologia. LWT è un messaggio contenente il topic, il QoS e un payload da inoltrare a tutti i subscriber che fino a quel momento ricevevano le notifiche. Questo pacchetto viene fornito nel momento in cui un client si connette per la prima volta al broker, prima che inizi l'invio effettivo dei dati per gli altri client. Se attraverso delle operazioni di ping, impostate con un certo timer, una delle due parti non riceve risposta, allora si assume esserci stata una disconnessione. A quel punto, se è il client ad essere offline, il broker invierà il Will ai subscribers. Un'ultima caratteristica importante per il funzionamento di MQTT, è la persistenza. Il broker mantiene le informazioni di sessione per i client disconnessi, in modo tale da riottenere facilmente le iscrizioni ai topic e i messaggi in coda che non avevano ricevuto (se si tratta di QoS1 e QoS2, pensati come già visto per la trasmissione affidabile). Inoltre, i publisher possono impostare un flag RETAINED nei messaggi, in modo tale che vengano salvati in maniera indefinita nel broker. L'obiettivo di questa funzionalità è garantire l'invio di un determinato messaggio ad un client indipendentemente dal momento della sua iscrizione al topic.

3.3 Protocolli di streaming

La rete IP è nata per la trasmissione di dati in zone geograficamente distanti tra loro. Le comunicazioni inizialmente erano basate sull'invio di file ed e-mail. La naturale estensione di questo meccanismo è stata quella di poter trasferire informazioni multimediali come animazioni, voce e video in tempo reale, il che ha comportato l'introduzione di nuovi requisiti nello stack IP. Se da un lato il protocollo di livello 3 era sufficiente per le comunicazioni più semplici, esso risultava inaffidabile sia in termini di mantenimento di informazioni, che di ordine di arrivo. L'introduzione del livello TCP ha risolto questa limitazione, ma con l'avvento dello streaming si sono presentati nuovi problemi, legati soprattutto alla latenza e al jitter, rispettivamente il tempo totale per la trasmissione di un pacchetto e la variabilità del delay.

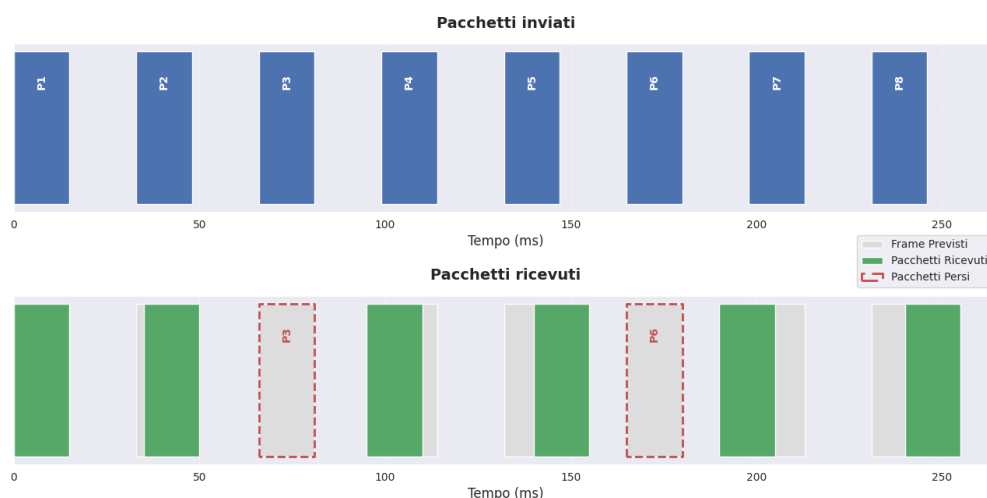


Figura 3.5: Effetto del jitter nella riproduzione dello streaming. Senza buffering i pacchetti non vengono riprodotti seguendo la stessa temporizzazione della sorgente.

Esistono 2 principali tipologie di software in questo contesto: interattivi (video-conferenze) e passivi (live-streaming). Nel primo caso i requisiti sul ritardo e sul jitter sono molto stringenti, per cui non si possono introdurre meccanismi pesanti di bufferizzazione, poiché compromettono irrimediabilmente la user experience. Possono invece essere implementati nel secondo, in modo tale da mitigare gli effetti della trasmissione. Bisogna ridurre al minimo i tempi di attesa: ad esempio il reinvio dei pacchetti, come succede in TCP, non può essere implementato. UDP invece si presta a questo meccanismo ed infatti fornisce la base per un protocollo di streaming in tempo reale. Non instaura nessun tipo di connessione e non deve monitorare le condizioni della rete per adattare la sua velocità nella comunicazione. Real-time Transport Protocol (RTP) è un protocollo di livello trasporto [8] è stato progettato per lavorare sopra UDP, e con le sue caratteristiche è in grado di soddisfare i requisiti per la trasmissione di dati multimediali su internet. RTP infatti permette la negoziazione di una codifica comune ai lati della comunicazione. Grazie a questo protocollo, i livelli applicativi sono liberi di implementare il buffering in base alle proprie necessità, poiché integra nei pacchetti il timestamp del contenuto multimediale. RTP non è sensibile al livello di congestione della rete, quindi il rate di trasmissione non viene modificato, come invece succede in TCP.

RTP lavora in coppia con Real-time Control Protocol (RTCP), la sua controparte per la verifica dello stato della rete. A differenza di TCP, questo protocollo ha una funzione di solo monitoraggio, non serve per reagire alle congestioni, quindi ai ritardi, alle perdite o al jitter. Si tratta di un protocollo leggero, che periodicamente invia messaggi di controllo verificando lo stato della rete, in modo tale che i livelli applicativi, in base alla qualità che vogliono fornire, reagiscano di conseguenza. Si è delegato quindi al software questo onere, senza fornire una maniera standard per il controllo del traffico. Questo è un grosso vantaggio in termini di flessibilità: sfruttando TCP al contrario, la velocità di trasmissione dipenderebbe dalle sue regole nella gestione del flusso di informazioni. Esiste infine un protocollo di più alto livello per la gestione delle sessioni nella trasmissione dati: Real-time Streaming Protocol (RTSP). Esso non invia i pacchetti effettivi per lo streaming, perché svolto interamente da RTP, ma una volta che la sessione è attiva, serve per inviare i comandi relativi allo stato di quest'ultima. Per cui il client che richiede dati multimediali manderà al server dei messaggi per avviare, sospendere o fermare il flusso di informazioni.

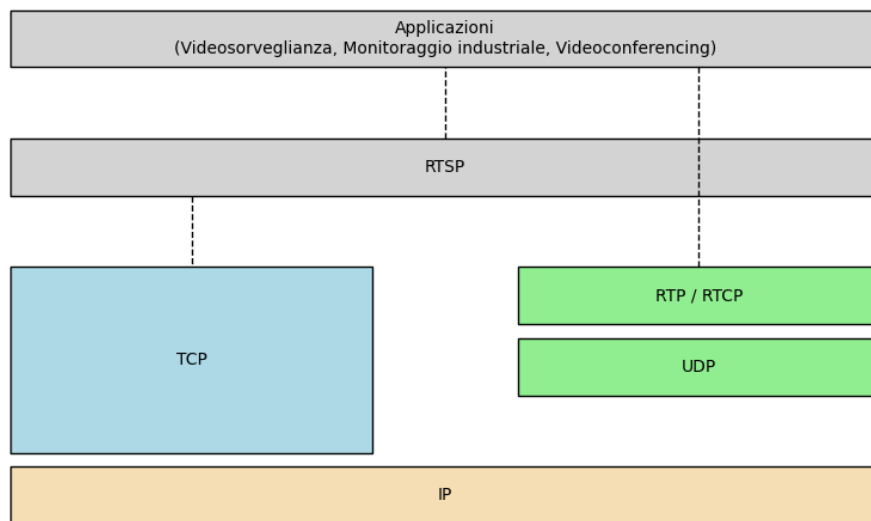


Figura 3.6: Stack di protocolli per lo streaming real-time.

Il formato dell'header RTP è costituito da tre elementi principali. I primi 12 bytes sono sempre presenti e formano il core del pacchetto. Successivamente possono esserci delle estensioni (anche se usate molto raramente) ed infine c'è il campo payload, il cui formato è deciso dall'applicazione. Nel

dettaglio i campi di RTP sono:

- **version:** bit per l'identificazione della versione di RTP usata nella trasmissione.
- **padding:** se questo campo è configurato, sarà presente del padding nel pacchetto, ad esempio per allineamento oppure se si sta utilizzando qualche algoritmo di cifratura.
- **extension:** quando il bit è attivo, il campo extension header sarà presente nel pacchetto.
- **CSRC Count:** conta il numero di sorgenti multiple, quando sono presenti, come spiegato nel campo CSRC.
- **marker:** identifica punti specifici nel flusso multimediale, come i confini tra diversi frame in un video.
- **payload type:** campo per la decodifica del contenuto multimediale nel payload.
- **sequence number:** numero identificativo del pacchetto. E' utile per stabilire se ci sia stata una perdita e permettere alle applicazioni di reagire. Queste possono decidere di non procedere in nessun modo oppure di attuare delle strategie. Ad esempio si potrebbe utilizzare delle codifiche che richiedono meno banda o riprodurre il frame precedente/successivo più volte.
- **timestamp:** indica il momento di generazione del pacchetto attraverso il clock di sistema. Serve per sincronizzare i flussi audio e video. Viene inoltre utilizzato per determinare il jitter.
- **Synchronization Source Identifier(SSRC):** identifica la sorgente nella comunicazione RTP. E' un valore scelto in randomicamente a livello locale dalle fonti, quindi esiste la possibilità di collisioni. In tal caso RTCP non permette che questo evento si verifichi, facendo uscire e rientrare dalla sessione una delle due sorgenti.
- **Contributing Source Identifiers(CSRC):** è una lista delle sorgenti che contribuiscono al payload del pacchetto, anche se in generale il source è solitamente uno solo. E' utile nel caso delle videoconferenze

quando più fonti generano un stream di dati, ma si vuole compattare i flussi in un unico pacchetto per necessità di banda.

In RTP non è presente un concetto esplicito di sessione, ma esso viene definito contestualmente alla generazione dello streaming, identificando il destinatario tramite indirizzo IP e una coppia di porte RTP ed RTCP.

RTSP è nato come standard per la definizione delle sessioni multimediali ed il loro controllo. In RFC2326 è definito come "remote control" nella gestione dello streaming, perché si presenta con una serie di comandi, che ricordano molto quelli di HTTP. Tuttavia differisce da questo protocollo in un punto fondamentale: RTSP è simmetrico, in quanto sia il client che il server multimediale possono inviare richieste. Inoltre i messaggi non sono di tipo fire and forget, infatti i comandi inviati possono riferirsi a richieste precedenti, rendendo di fatto RTSP un protocollo stateful[9]. Non è un meccanismo orientato alle connessioni, per cui anche appoggiandosi a TCP potrebbe più volte aprire diverse comunicazioni attraverso il protocollo di livello trasporto nella stessa sessione RTSP. In generale il suo funzionamento non dipende dal protocollo di livello 4 sottostante, per cui si può appoggiare sia a TCP che ad UDP nella generazione dei propri messaggi, ma tipicamente viene utilizzato TCP. Nonostante i requisiti di bassa latenza per l'intero sistema di streaming, nel caso di RTSP è importante che i comandi arrivino a destinazione, per cui si utilizza un canale di comunicazione affidabile, separato dal flusso vero e proprio. Questo non comporta degrado delle prestazioni perché i pacchetti sono su un canale separato e la quantità è talmente limitata che non impatta sulla banda disponibile. Infine, per quanto riguarda le sue caratteristiche, bisogna menzionare come vengono identificati gli stream. Si sfrutta un RTSP URL (e.g. `rtsp://hostname/video/front`), in maniera molto simile a come vengono definite le risorse in HTTP. Questo mapping è molto utile perché può applicare i comandi a più stream contemporaneamente, seguendo la struttura gerarchica dei path nell'URL. Ad esempio se ci sono più flussi video, come `rtsp://hostname/video/front` e `rtsp://hostname/video/top`, inviando un comando a `rtsp://hostname/factory/video`, questo si applicherà ad entrambe le risorse. I metodi disponibili in RTSP sono:

- **OPTIONS:** insieme dei comandi che entrambe le parti possono accettare, serve quindi per verificare la compatibilità delle operazioni disponibili tra gli estremi di comunicazione.

- **DESCRIBE**: questo comando fornisce la descrizione del contenuto multimediale come il formato e la codifica.
- **SETUP**: inizializza la sessione di streaming RTSP, tramite dei parametri (e.g. porta, protocollo di trasporto) dopo che entrambe le parti hanno allocato le risorse necessarie.
- **PLAY**: il client invia questo comando quando richiede l'effettiva trasmissione del flusso.
- **PAUSE**: lo streaming viene interrotto dal client senza che il server liberi le risorse e i parametri di sessione.
- **TEARDOWN**: il client richiede lo stop dello streaming, seguito dalla liberazione delle risorse nel server.
- **GET_PARAMETER, SET_PARAMETER**: questa serie di comandi fornisce o imposta i parametri di sessione nello streaming (ad esempio i pacchetti ricevuti, il jitter etc).

RTSP definisce una macchina a stati, che permette la coordinazione del flusso di streaming multimediale, in modo tale da consentire ai partecipanti della sessione di sapere quali comandi possono inviare o ricevere in ogni sua fase. Sia il client che il server memorizzano lo stato della sessione per avere una interazione coerente tra di loro.

3.4 Amazon Web Services

Amazon Web Services (AWS) è una piattaforma pubblica basata su cloud che offre servizi gestiti per la generazione di soluzioni a diversi livelli di astrazione. Per quanto riguarda lo storage ad esempio, si potrebbe richiedere al provider una macchina virtuale e collegare ad essa un volume, implementando così una soluzione di basso livello. Altrimenti è possibile sfruttare servizi come S3 e salvare le proprie informazioni attraverso una API, ottenendo un risultato simile, ma ad alto livello. La scelta dipende sempre dalle necessità dell'utente, tuttavia l'opzione più facile è sicuramente la seconda, perché con una semplice chiamata si possono salvare le proprie informazioni come se si utilizzasse un filesystem remoto, senza preoccuparsi della gestione interna, della durabilità, delle dimensioni dei file ed in generale della grandezza dello storage, che può scalare teoricamente in maniera indefinita.

Le API sono accessibili attraverso protocolli web, coerente con le caratteristiche fornite da NIST per quando riguarda il cloud computing. Tra queste infatti è presente il concetto di "broad network access", cioè le funzionalità del cloud computing vengono erogate attraverso la rete. Altre proprietà comprendono la possibilità di ottenere i servizi su richiesta da parte dell'utente senza ausili esterni (on-demand self-service), condivisione di un'unica piattaforma da parte degli utenti (resource pooling), risposta rapida alla richiesta di risorse imposte dalla variabilità nel workload (rapid elasticity). L'adozione del cloud computing viene spesso sponsorizzata per il modello dei costi lato utente, basata sul pay-per-use. Questo significa ridurre le spese nel caso di startup che non possiedono una infrastruttura IT, oppure per aziende che vogliono ricostruire o estendere la propria. Inizialmente può essere un vantaggio, ma bisogna sempre monitorare l'utilizzo e l'architettura delle proprie soluzioni in modo che i costi operativi non esplodano. In generale quindi il modello introdotto da Amazon può essere considerato un beneficio, tuttavia si tratta del punto di partenza per esplorare ulteriori vantaggi che il provider introduce.

AWS è una piattaforma innovativa, che annuncia costantemente nuovi prodotti. L'implementazione di queste tecnologie viene poi integrata nell'ecosistema esistente, contribuendo al continuo allargamento della piattaforma. I servizi gestiti forniti dal provider sono pensati per risolvere problemi comuni, in modo tale che il cliente si focalizzi solo sulle soluzioni. Per cui non sarà necessario implementare meccanismi di load balancing o per le notifiche in quanto AWS fornisce queste funzionalità a priori. Il paradigma Infrastructure as Code (IaC) rende la gestione delle risorse automatica: si tratta di un effetto collaterale dell'utilizzo delle API. L'utente deve solo dichiarare le risorse necessarie, non gestire manualmente la loro allocazione. Una volta definite le parti del sistema, sarà compito di AWS invocare i comandi che servono per la loro creazione. La capacità del cloud si può adattare in proporzione al carico di lavoro, definendo un numero di macchine virtuali in base alla periodicità (giorni, settimane, mesi) e a quando vengono raggiunti i picchi. Basta incrementare il numero di macchine virtuali e quando non saranno più necessarie eliminarle. Questo meccanismo avviene molto velocemente, quindi non si tratta solo di un vantaggio di scalabilità, ma anche di velocità di allocazione e deallocazione delle risorse. AWS offre dei servizi che sono affidabili by default: ad esempio S3 è progettato per avere una durabilità dei dati al 99,9%. Inoltre vengono forniti strumenti per rendere la propria infrastruttura affidabile, non limitandosi quindi solo ai servizi,

ma anche a livello di sistema. La possibilità di poter deployare la propria infrastruttura in più regioni rientra in questa categoria. Oltre ad essere un vantaggio in termini di accessibilità, latenza e protezione dei dati, quando una delle repliche possiede un guasto, si può continuare a garantire il servizio utilizzando il deploy di un'altra regione. Inoltre, sempre nell'ottica dell'affidabilità, vengono forniti dei servizi per il monitoraggio e l'alerting dell'infrastruttura, come nel caso di Amazon CloudWatch e AWS X-Ray. Si possono così controllare le metriche principali come latenza, utilizzo delle risorse e throughput. Nel momento in cui si verificano anomalie si possono poi impostare degli avvisi per reagire tempestivamente agli eventi inattesi.

Come si può notare in Figura 3.7, i servizi offerti da AWS si dividono in due categorie: hardware e software, basati sull'infrastruttura sottostante[10]. Poiché in questo lavoro si è sfruttato unicamente il modello Platform as a Service (PaaS) e Software as a Service (SaaS), il focus della classificazione nell'analisi sarà solo sulla parte software.

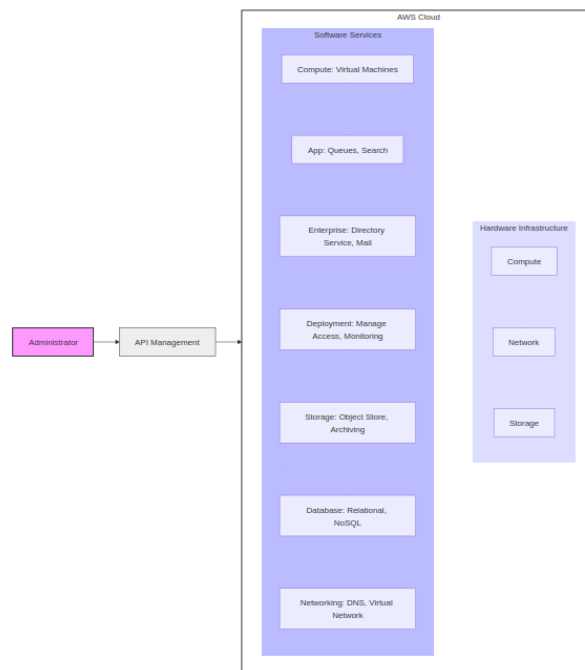


Figura 3.7: Classificazione ad alto livello dei servizi AWS. Accessibili attraverso API, si dividono nelle due macro-aree hardware e software.

Per quanto riguarda la categoria compute, l'obiettivo è quello di fornire rispettivamente servizi per l'esecuzione di applicazioni su macchine virtuali

e per la gestione delle risorse di calcolo, come nel caso di Elastic Compute Cloud (EC2). Per app si intendono quei servizi a diretto supporto delle applicazioni, necessari per la risoluzione di problemi comuni, come l'implementazione delle code di messaggi o delle notifiche. I servizi enterprise sono pensati per la gestione delle risorse aziendali, ad esempio Organizations è un tool per il controllo di più account AWS, in modo tale da poter effettuare raggruppamenti in base alle unità nell'organizzazione ed aggregare policy e operazioni per ciascun gruppo. La categoria deployment, come si può facilmente intuire, fornisce strumenti per la distribuzione del software. Storage è l'insieme dei servizi per la memorizzazione dei dati in modo sicuro, scalabile e di lunga durata. Tra questi rientrano sicuramente gli object store come S3 e i servizi di archiviazione a lungo termine e backup come Glacier. Le ultime due categorie riguardano i database (RDS per i relazionali, DynamoDB per quelli non relazionali) ed il networking come Virtual Private Cloud (VPC) per la creazione di reti isolate nel cloud. In Tabella 3.1, infine, viene mostrata la tassonomia, secondo le classi appena definite, dei servizi usati nell'implementazione del sistema di rilevazione dei DPI, con una breve descrizione del loro funzionamento, approfondito nel capitolo successivo.

Servizio	Categoria	Descrizione
CloudFormation	Deployment	Tramite il paradigma Infrastructure as Code, permette la dichiarazione di uno stack con le risorse necessarie ed indica le policy di accesso tra i vari servizi.
Lambda	Compute	Funzione utilizzata in architetture event-driven, programmata senza dover gestire l'infrastruttura sottostante (macchine virtuali, sistemi operativi).
IAM Policy	Enterprise	Consente di definire le regole di accesso e autorizzazione tra servizi AWS, rendendo possibili interazioni sicure e controllate.

Kinesis-Video Streams	App	Gestisce in maniera scalabile l'ingestion di flussi multimediali dall'esterno del cloud e li inoltra a servizi downstream, come S3, EC2 o applicazioni di machine learning (e.g. Rekognition).
Kinesis-Data Streams	App	Progettato per gestire flussi di dati non multimediali (JSON, testo), provenienti da fonti come sensori IoT, inoltrati successivamente a servizi big data come Kinesis Data Analytics(KDA) o per lo storage (S3, DynamoDB)
Kinesis-Data Analytics	App	Utilizzato per analisi dei dati in real-time provenienti da flussi generati da Kinesis Data Streams oppure Apache Kafka
Amazon Rekognition	App	Sfrutta modelli di Deep Learning per identificare oggetti, persone, scene all'interno di immagini e video.
AWS IoT Core e Greengrass	App	Controllano in maniera coordinata lo stato dei dispositivi IoT e inoltrano i relativi messaggi di telemetria provenienti dall'edge.

Tabella 3.1: Classificazione dei servizi AWS di interesse.

Fatta eccezione per Amazon Rekognition, tutti questi servizi rientrano nella categoria PaaS, in quanto gran parte della gestione è delegata ad AWS, ma sono presenti delle ulteriori configurazioni perché possano funzionare correttamente. Ad esempio Kinesis Data Analytics richiede di sviluppare applicazioni come Apache Flink e di collegare sorgenti e destinazioni. Come già visto nel precedente capitolo invece, per usare Amazon Rekognition basta invocare la sua API e si otterrà subito una risposta, senza ulteriore overhead di gestione.

3.5 Apache Flink

Capitolo 4

Implementazione del sistema

4.1 Architettura

L'obiettivo del sistema proposto è quello di generare una infrastruttura scalabile per l'analisi di dati semistrutturati e non strutturati all'interno di una fabbrica, attraverso un prototipo. In particolare, dato un insieme di macchinari, come ad esempio bracci robotici, quel che si vuole ottenere è il controllo dell'effettivo indossamento dei dispositivi di sicurezza da parte degli operatori (operai, manutentori) all'interno di uno stabilimento, in modo tale da garantire loro la sicurezza sul posto di lavoro. L'architettura proposta è di tipo event-driven, per cui il processamento dei dati avviene solo quando si verifica una situazione particolare sull'edge, dato il seguente scenario: uno o più operatori entrano all'interno di una certa area definita da un insieme di ancore, su cui sono montati dei sensori e si trovano in prossimità di un macchinario attivo; due telecamere, una superiore ed una frontale monitorano l'area di sicurezza. Se almeno uno degli operatori non possiede i dispositivi di sicurezza, il sistema deve generare un allarme e spegnere il macchinario. Lo stesso tipo di reazione deve verificarsi se almeno uno degli operatori non è abilitato ad operare sulla macchina. Infatti, coloro che possono lavorare indossano un tag attivo che trasmette informazioni ai sensori sulle ancore.

Il design è quello di un' applicazione cloud nativa e si divide in due sottosistemi tra di loro connessi: da un lato l'edge, composto da una telecamera superiore accoppiata ad una frontale, dei sensori ed un gateway; dall'altro




Figura 4.1: Schema dello use case.

il cloud formato da servizi gestiti dal provider AWS. Il progetto non è una classica applicazione client-server, ma un insieme di servizi gestiti che globalmente opera near-real time e si serve di dispositivi IoT sia per la rilevazione degli eventi che per l'ingestion dei dati sul cloud. Nel primo caso viene utilizzato MQTT per la telemetria. Nel secondo invece, vengono connesse le telecamere ad un gateway attraverso il protocollo RTSP e successivamente questo si occupa dell'ingestion effettiva, sfruttando una libreria Amazon apposita.

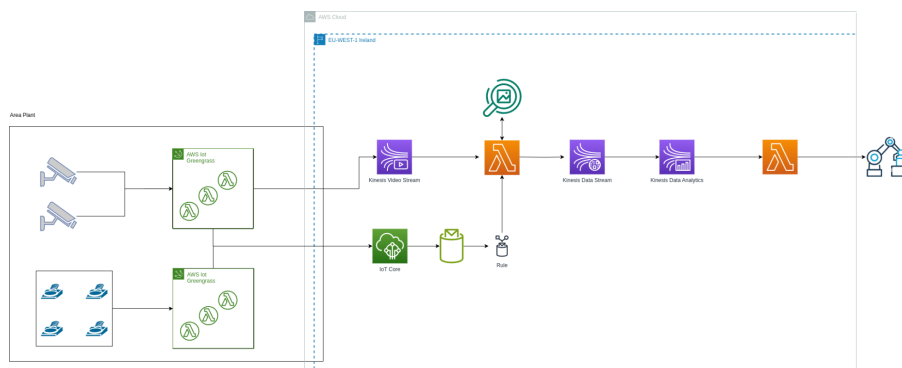


Figura 4.2: Architettura ad alto livello del sistema.

Il gateway posto tra i dispositivi e il cloud non serve solo per garantire la necessaria potenza di calcolo per l'invio dei dati, ma è un componente

imprescindibile per l'integrazione con AWS. Al suo interno infatti è installato un software fondamentale per la realizzazione del sistema: IoT Greengrass. Una delle sue funzionalità più importanti è quella di installare sull'edge componenti software caricati dal cloud. Esso consente uno sviluppo del progetto molto più rapido e semplice, consen. Si occupa di problemi come:

- **sicurezza sull'edge e dei dati in transito:** Greengrass è installato con permessi di root e sfrutta le user permission per l'anti-tampering del codice dopo il deploy. Per la comunicazione in entrata ed uscita, si serve di certificati relativi alla public key infrastructure (PKI) rilasciati da aws. Per cui, tramite autenticazione, cifratura e integrità dei dati sia la comunicazione che i deploy sono sicuri di default.
- **orchestrazione del runtime:** i componenti che vengono deployati dal cloud verso l'edge, in qualsiasi forma essi siano (monoliti, servizi o container) possono essere gestiti dall'ambiente in modo da definire dipendenze tra i vari componenti ed un lifecycle per ciascuno di essi.
- **logging e monitoraggio:** questa integrazione è fondamentale soprattutto per dispositivi che non sono facilmente accessibili da remoto. I log generati dai componenti possono essere automaticamente sincronizzati con servizi cloud aws come cloudwatch. Inoltre lo stato dei dispositivi è automaticamente tracciato in modo tale da controllare quelli che riscontrano dei problemi e rispondere rapidamente agli errori.
- **scalabilità del deployment:** con Greengrass possono essere definiti gruppi di dispositivi su cui deployare dei componenti. Un dispositivo può appartenere anche a più gruppi e può quindi ricevere diversi deployment contemporaneamente. La definizione di questi insiemi permette quindi un controllo granulare delle istanze per le quali serve fare merging di diversi deployment.

L'obiettivo di questi primi paragrafi è quello di descrivere i componenti hardware e software sull'edge ed i servizi gestiti sul cloud che si occupano dell'ingestion dei dati in maniera sicura, robusta e scalabile, con accenni sulla trasformazione e il preprocessing dei dati(vedi Figura 4.3). In questa soluzione, Greengrass è installato all'interno di un container Docker che ha come immagine di base la più recente versione di Amazon Machine Image (AMI), pensata per essere integrata con AWS e quindi essere più efficiente e

sicura all'interno dell'infrastruttura cloud. Questa macchina virtuale è stata customizzata in modo da supportare sia le dipendenze di Greengrass, che quelle per GStreamer, un tool per l'inoltro dello streaming, che collabora con la libreria apposita per l'invio sul cloud. L'ingestion dei dati video e di quelli provenienti dai sensori è separato ed avviene in due modalità differenti. Una volta che il componente video viene deployato inizia ininterrottamente a streammare su KVS, mentre il publisher che genera l'evento, inviandolo ad un broker su AWS IoT, si attiva solamente alla rilevazione da parte dei sensori di uno o più operatori.

Attraverso Greengrass è possibile generare lo stesso runtime che sul cloud permette l'esecuzione di uno dei componenti più noti in AWS, cioè Lambda, una funzione gestita direttamente dal provider, che elimina la necessità di configurazione di macchine virtuali, sistemi operativi e scalabilità. Il tutto avviene nell'ottica di concentrarsi solo sullo sviluppo della logica per la reazione agli eventi. In questo modo i sensori pubblicheranno i dati su una coda MQTT locale, come il numero di tag rilevati o la macchina cui si fa riferimento, e successivamente la Lambda sull'edge, iscritta al relativo topic, si attiverà alla pubblicazione di queste informazioni. Una volta eseguita una prima elaborazione, la funzione pubblicherà su un topic in IoT Core, generando un evento in formato JSON.

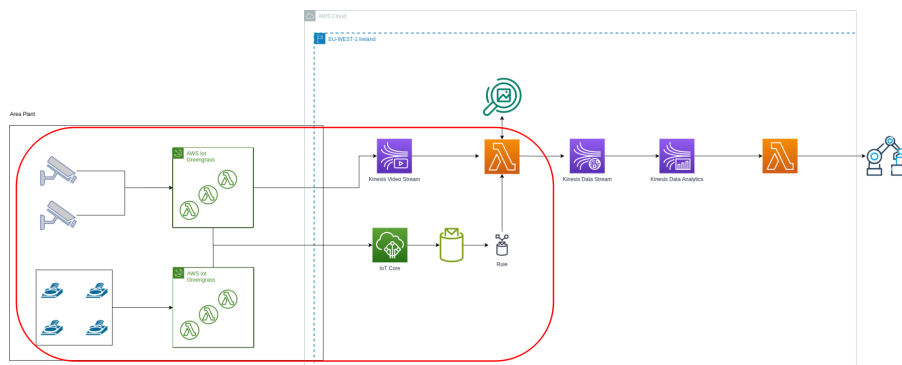


Figura 4.3: Sottosistema di ingestione e preprocessing.

Al messaggio MQTT vengono applicate delle regole, in modo tale da filtrare i dati, successivamente trasmessi ad un'altra Lambda che si trova sul cloud, la quale si occupa del processamento dello streaming video. A valle dell'analisi viene prodotto uno stream di dati verso un'applicazione big data. Nel dettaglio, il flusso iniziale viene separato in due, in quanto la Lambda è

progettata per elaborare uno streaming video alla volta ed i flussi streaming da analizzare in parallelo provengono, come già visto, da una telecamera frontale e una superiore. Per cui ogni evento che triggera la Lambda deve contenere un riferimento allo stream: in questo modo, contemporaneamente, due istanze diverse della stessa Lambda verranno attivate a valle del topic filter.

Per concludere il quadro della descrizione architetturale, bisogna focalizzarsi sui dati in uscita dalla Lambda. Ogni frame analizzato dallo streaming video viene inviato in modalità asincrona sul servizio gestito Kinesis Data Stream (KDS), il quale permette la trasmissione di grandi flussi di dati in real-time. Queste informazioni possono essere successivamente analizzate in parallelo su dei cluster, dopo aver deployato una opportuna applicazione big data. Si tratta quindi del centro di elaborazione all'interno dell'architettura, in quanto è il punto in cui tutti gli eventi vengono uniti dalle diverse sorgenti IoT, che siano le telecamere o i sensori. In questo progetto è stata sviluppata una applicazione con Apache Flink, come già visto nel capitolo precedente, il framework e motore di processamento distribuito per flussi di dati streaming sia limitati che illimitati. A differenza di altre soluzioni, come Apache Spark, questo framework non solo supporta il batching, ma anche l'analisi di singoli record provenienti da un flusso di dati real-time. Amazon offre un servizio gestito per l'analisi chiamato Kinesis Data Analytics, ma per gli esempi e la ridotta scala dei dati è stato scelto di deployare l'applicazione su una istanza EC2. Il risultato è equivalente e il codice non deve essere modificato per funzionare su un eventuale cluster. Infine, all'estremo del sistema è presente un'ultima Lambda, la cui responsabilità è quella di restituire gli allarmi generati in fase di processamento.

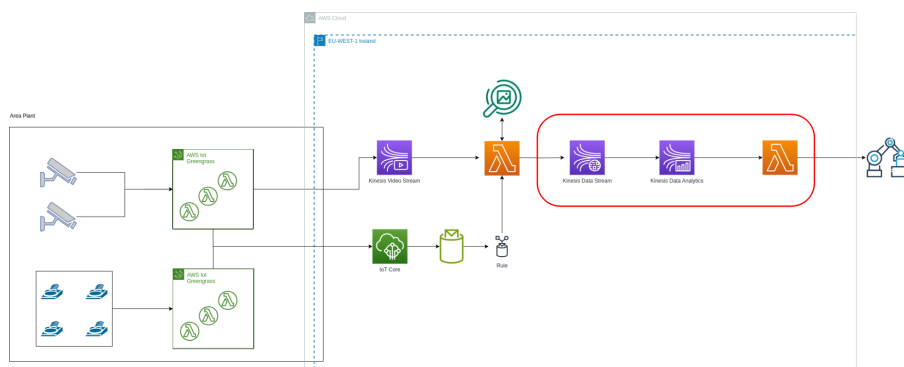


Figura 4.4: Moduli di processamento e generazione degli allarmi.

4.2 Edge Runtime/Ingestion

4.3 Preprocessing e trasformazione dei dati

La parte di preprocessing, come visto nella descrizione generale, avviene tramite il coordinamento di diversi managed services, il cui fulcro è la funzione Lambda. Essa implementa la trasformazione dello streaming video in uno flusso di dati in tempo reale, integrando vari servizi AWS in maniera scalabile, efficiente e soprattutto automatica, in base al numero di flussi ricevuti. I servizi utilizzati all'interno della Lambda sono Kinesis Video Streams (KVS), Amazon Rekognition, Kinesis Data Streams ed opzionalmente S3. La funzione è implementata in Python e sfrutta internamente il multithreading per l'ottimizzazione delle prestazioni. Alla base di questo sistema c'è la `'lambda_handler'`, i.e. l'entrypoint del codice, invocata all'arrivo di un nuovo evento e generato da una topic rule. In termini più specifici, questo tipo di attivazione prende il nome di trigger e viene gestito dall'infrastruttura AWS. In generale, nella maggior parte dei casi, la comunicazione dei servizi all'interno del cloud è completamente trasparente all'utente.

4.4 Big data processing

4.5 Deployment

Capitolo 5

Risultati

5.1 Metriche ed Analisi

5.2 Limitazioni

Conclusioni

Appendice A

Codice

Appendice B

Approfondimenti Tecnici

Equivalenza algebrica tra perceptron e filtro convoluzionale su una regione dell'immagine

Un **perceptron** è un modello neurale che calcola un output y basato su un insieme di input $\mathbf{x} = [x_1, x_2, \dots, x_n]$, pesi associati $\mathbf{w} = [w_1, w_2, \dots, w_n]$, e un bias b . La formula del perceptron è:

$$y = \phi \left(\sum_{j=1}^n w_j x_j + b \right)$$

Dove:

- ϕ è la funzione di attivazione (ad esempio, ReLU, Sigmoid, Step Function).
- $\sum_{j=1}^n w_j x_j + b$ è la somma pesata degli input più il bias.

Convoluzione su una Singola Regione dell'Immagine

Consideriamo una regione \mathbf{R}_i dell'immagine di dimensioni $M \times N$ e un filtro \mathbf{K} (o kernel) di dimensioni $M \times N$. L'operazione di **convoluzione** su questa regione è definita come:

$$S_i = \sum_{m=1}^M \sum_{n=1}^N K(m, n) \cdot R_i(m, n) + b$$

Dove:

- S_i è il risultato della convoluzione prima dell'applicazione della funzione di attivazione.
- $K(m, n)$ sono i pesi del filtro.
- $R_i(m, n)$ sono i pixel della regione \mathbf{R}_i dell'immagine.
- b è il bias.

Espansione Completa della Sommatoria

Espandiamo la sommatoria per una specifica regione \mathbf{R}_i di dimensioni 3×3 :

$$\begin{aligned} S_i = & K(1,1) \cdot R_i(1,1) + K(1,2) \cdot R_i(1,2) + K(1,3) \cdot R_i(1,3) \\ & + K(2,1) \cdot R_i(2,1) + K(2,2) \cdot R_i(2,2) + K(2,3) \cdot R_i(2,3) \\ & + K(3,1) \cdot R_i(3,1) + K(3,2) \cdot R_i(3,2) + K(3,3) \cdot R_i(3,3) + b \end{aligned}$$

Rappresentazione come Prodotto Scalare

Possiamo rappresentare questa operazione come un **prodotto scalare** tra due vettori appiattiti: uno che contiene i pixel della regione \mathbf{R}_i e l'altro che contiene i pesi del filtro \mathbf{K} .

Definiamo i vettori appiattiti:

$$\mathbf{x}_i = \begin{bmatrix} R_i(1,1) \\ R_i(1,2) \\ R_i(1,3) \\ R_i(2,1) \\ R_i(2,2) \\ R_i(2,3) \\ R_i(3,1) \\ R_i(3,2) \\ R_i(3,3) \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} K(1,1) \\ K(1,2) \\ K(1,3) \\ K(2,1) \\ K(2,2) \\ K(2,3) \\ K(3,1) \\ K(3,2) \\ K(3,3) \end{bmatrix}$$

Il prodotto scalare tra \mathbf{w} e \mathbf{x}_i è:

$$\begin{aligned} \mathbf{w} \cdot \mathbf{x}_i = & K(1,1)R_i(1,1) + K(1,2)R_i(1,2) + K(1,3)R_i(1,3) \\ & + K(2,1)R_i(2,1) + K(2,2)R_i(2,2) + K(2,3)R_i(2,3) \\ & + K(3,1)R_i(3,1) + K(3,2)R_i(3,2) + K(3,3)R_i(3,3) \end{aligned}$$

Quindi, possiamo riscrivere S_i come:

$$S_i = \mathbf{w} \cdot \mathbf{x}_i + b$$

Convoluzione con Funzione di Attivazione

Dopo aver calcolato S_i , applichiamo una **funzione di attivazione** ϕ per ottenere l'output y_i :

$$y_i = \phi(S_i) = \phi(\mathbf{w} \cdot \mathbf{x}_i + b)$$

Equivalenza con la Formula del Perceptron

La formula del **perceptron** è data da:

$$y = \phi \left(\sum_{j=1}^n w_j x_j + b \right)$$

Dove:

- $\mathbf{x} = [x_1, x_2, \dots, x_n]$ sono gli input.
- $\mathbf{w} = [w_1, w_2, \dots, w_n]$ sono i pesi.
- b è il bias.
- ϕ è la funzione di attivazione.

Confrontando le due formule, vediamo che:

$$y_i = \phi(\mathbf{w} \cdot \mathbf{x}_i + b) = \phi \left(\sum_{i=1}^n w_i x_i + b \right) = \phi \left(\sum_{j=1}^n w_j x_j + b \right)$$

Stratificazione del filesystem in Docker

Macchina degli stati in RTSP

Modelli di distribuzione dei servizi cloud

Bibliografia

- [1] I. N. per l'Assicurazione contro gli Infortuni sul Lavoro (INAIL), "Rapporto annuale inail 2023," 2023, accesso: 24 settembre 2024. [Online]. Available: <https://www.inail.it/content/dam/inail-hub-site/documenti/2023/09/infografiche-relazione-annuale-inail-2022.pdf>
- [2] O. Safety and H. A. E. Union, "Il valore della sicurezza e della salute sul lavoro e i costi sociali degli infortuni e delle malattie professionali," 2019, accesso: 26 settembre 2024. [Online]. Available: https://osha.europa.eu/sites/default/files/Summary_Value_of_OSH_and_societal_costs_injuries_and_diseases_IT.pdf
- [3] G. U. della Repubblica Italiana, "Decreto legislativo 81/2008," 2008, accesso: 18 ottobre 2024. [Online]. Available: <https://www.gazzettaufficiale.it/eli/id/2008/04/30/008G0104/sg>
- [4] G. U. dell'Unione Europea, "Regolamento (ue) 2016/42," 2016, accesso: 22 ottobre 2024. [Online]. Available: <https://eur-lex.europa.eu/legal-content/IT/TXT/PDF/?uri=CELEX:32016R0425>
- [5] D. Hubel and T. Wiesel, "Receptive fields of single neurones in the cat's striate cortex," 1959, accesso: 26 ottobre 2024. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC1363130/pdf/jphysiol01298-0128.pdf>
- [6] J. Manyika, L. Woetzel, and R. Dobbs. (2015) Unlocking the potential of the internet of things. Accesso: 24 ottobre 2024. [Online]. Available: <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-internet-of-things-the-value-of-digitizing-the-physical-world>
- [7] P. Lea, *IoT and Edge Computing for Architects*, second edition ed. Packt Publishing, 2020.
- [8] H. Schulzrinne, "Rtp: A transport protocol for real-time applications," 2003, accesso: 12 Novembre 2024. [Online]. Available: <https://www.ietf.org/rfc/rfc3550.txt>

- [//www.rfc-editor.org/rfc/rfc2326.html](https://www.rfc-editor.org/rfc/rfc2326.html)
- [9] —, “Real time streaming protocol (rtsp),” 1998, accesso: 15 Novembre 2024. [Online]. Available: <https://www.rfc-editor.org/rfc/rfc2326.html>
- [10] A. Witting and M. Witting, *Amazon Web Services in Action*, second edition ed. Manning Publications, 2019.